Geração Automática de Insights em Dashboards de Gestão Universitária com Inteligência Artificial Generativa

Palavras-Chave: inteligência artificial, *dashboards* institucionais, *storytelling* visual, carga cognitiva

Autores

EDSAMUEL DA SILVA ROCHA, FATEC AMERICANA

LARA FABYÃ DOS SANTOS, FATEC AMERICANA

Prof. Dr. JOÃO EMMANUEL D'ALKIMIN NEVES, FATEC AMERICANA

1. INTRODUÇÃO

Dashboards institucionais são amplamente utilizados em universidades para apoiar a tomada de decisão. Em instituições de ensino superior de grande porte, a gestão acompanha continuamente Indicadores-Chave de Desempenho (*KPIs*) como evasão, matrículas, retenção e concluintes, distribuídos por curso e modalidade. Contudo, apresentar esses indicadores de forma puramente gráfica e isolada eleva a carga cognitiva do gestor, exigindo cruzamentos manuais, o que confirma Shneiderman (2004), para quem visualizações sem camada interpretativa demandam esforço cognitivo adicional. Embora estudos recentes exploram a geração automatizada de narrativas, ainda são pouco investigadas arquiteturas que apliquem IA generativa e *storytelling* visual à interpretação de *KPIs* de gestão universitária, especialmente com requisitos de segurança institucional. Nesse sentido, estudos recentes indicam que data *storytelling* automatizado, combinando visualizações e texto, podem melhorar a eficiência e a efetividade na compreensão de informações extraídas de dados (Islam *et al*., 2024).

Diante desse cenário, surge a questão: é possível utilizar IA generativa e *storytelling* visual para produzir *insights* organizados e contextualizados, com potencial para facilitar a interpretação de *dashboards* institucionais? Este trabalho parte da hipótese de que a combinação entre IA generativa e *storytelling* visual é capaz de produzir interpretações automáticas mais organizadas e contextualizadas dos indicadores institucionais, com potencial para reduzir o esforço cognitivo necessário à sua interpretação. A proposta apoia-se em Davenport (2007), para quem o valor real dos dados reside em transformá-los em análises acionáveis. Como contribuição, este trabalho apresenta uma arquitetura capaz de integrar IA generativa e *dashboards* institucionais para geração automática de *insights* estratégicos, preservando requisitos de segurança, privacidade e organização narrativa das informações.

Como o projeto envolve dados de estudantes, a arquitetura incorpora anonimização, validação de entrada/saída e controle de acesso, em conformidade com a LGPD (Lei nº 13.709/2018). Alinhado aos objetivos de inovação do CIC Unicamp, o alcance deste estudo limita-se a um ambiente experimental com dados simulados representativos, sem implantação operacional imediata.

2. OBJETIVOS

O objetivo geral deste projeto é desenvolver e avaliar um sistema baseado em Inteligência Artificial para a geração automática de *insights* estratégicos a partir de *KPIs* institucionais, analisando sua capacidade de sintetizar, organizar e contextualizar os indicadores em comparação a um *dashboard* tradicional. Os objetivos específicos são:

- **Implementar um motor de IA:** integrar um modelo de linguagem de grande escala (*LLM*), o Google Gemini, capaz de processar dados institucionais de evasão, matrículas, retenção e concluintes.
- **Gerar funcionalidades de *insights* automáticos:** produzir resumos executivos, destaques de desempenho, tendências emergentes e alertas proativos em linguagem natural, complementando as visualizações gráficas já existentes.

- **Comparar o modelo tradicional e o modelo com IA:** avaliar, lado a lado, um *dashboard* exibindo apenas gráficos e um *dashboard* híbrido, combinando visualização e explicação textual, a partir dos mesmos *KPIs*.
- **Avaliar a qualidade dos *insights* gerados:** medir objetivamente a cobertura de *KPIs* críticos e a compressão informacional obtida pela IA.
- **Incorporar requisitos e controles iniciais de cibersegurança ao sistema:** incorporar anonimização, controle de acesso e validação de entradas e saídas ao longo do processamento pela IA, definindo também requisitos para futura implementação de auditoria e monitoramento contínuo.

3. METODOLOGIA

A metodologia seguiu uma abordagem de pesquisa e desenvolvimento, estruturada em quatro frentes: (i) construção da arquitetura de processamento de dados e geração de *insights*; (ii) comparação entre uma versão tradicional e uma versão com IA do mesmo *dashboard*; (iii) incorporação de medidas de cibersegurança; e (iv) definição de métricas objetivas de avaliação.

3.1 Arquitetura do Sistema e Processamento de Dados

A arquitetura foi concebida de forma modular para permitir futura integração com diferentes fontes de dados e modelos de IA. Nesta etapa, a implementação experimental utilizou o Google Gemini. O fluxo inicia com a ingestão de *KPIs* institucionais (evasão, matrículas, retenção e concluintes), que passam por pré-processamento e anonimização antes do envio ao Google Gemini (Google, 2024) para detecção de anomalias e redação de saídas textuais, conforme o fluxo da Figura 1.

Figura 1 - *Fluxo de arquitetura: do processamento dos dados brutos à entrega na interface híbrida ao gestor*



Fonte: Elaborado pelos autores (2026).

A geração de insights pelo Gemini envolve a análise dos dados pré-processados e a produção de insights classificados por grau de severidade (alerta, atenção ou positivo), explicação textual e, quando pertinente, sugestão de ação.

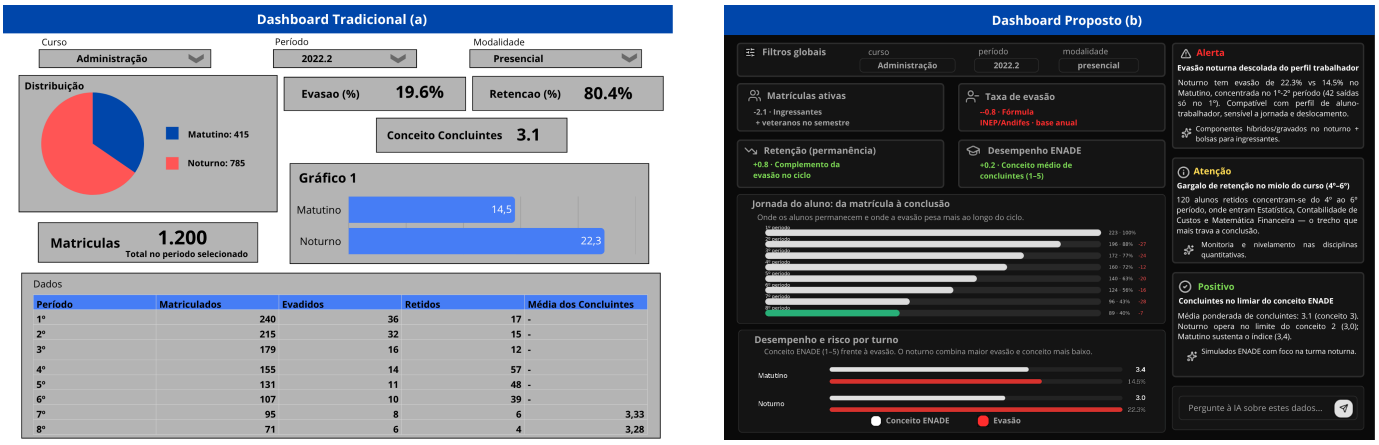
Os dados pré-processados foram estruturados em formato *JSON* e enviados ao Gemini 1.5 Flash, por meio da Gemini *API*. O *prompt* solicitou a identificação de variações relevantes, correlações entre *KPIs* e a geração de *insights* e sugestão de ação. Foram realizadas sete execuções com temperatura 0,2. As relações numéricas apresentadas nos textos foram posteriormente comparadas aos dados de origem pelos pesquisadores.

A organização dos *insights* foi orientada por princípios de *storytelling* visual, com priorização das informações críticas, apresentação progressiva do contexto, associação entre explicações textuais e gráficos correspondentes e diferenciação entre alertas, tendências e destaques positivos. A organização narrativa buscou articular dados, contexto e priorização da informação, conforme princípios de *storytelling* aplicados à comunicação apoiada por IA (McSILL, 2025).

3.2 Comparação entre *Dashboard* Tradicional e *Dashboard* com IA

Para analisar o ganho informacional da proposta e seu potencial de facilitar a interpretação, os mesmos *KPIs* foram apresentados em duas versões de um mesmo *dashboard*: uma versão tradicional, que exibe apenas os gráficos e valores brutos, exigindo que o gestor correlacione manualmente as informações; e uma versão com IA, que apresenta os gráficos acompanhados de *insights* classificados por severidade, gerados automaticamente, como esquematizado na Figura 2.

Figura 2 *- Comparativo entre Dashboard tradicional (a) e Dashboard proposto com IA para geração de insights (b)*



(a) (b)

Fonte: Elaborado pelos autores (2026).

3.3 Cibersegurança e Privacidade dos Dados

A cibersegurança foi tratada como componente estrutural do sistema, seguindo princípios de engenharia de segurança amplamente estabelecidos na literatura, defesa em profundidade, minimização de dados e controle de acesso por perfil (Anderson, 2020). No protótipo atual, foram implementadas as seguintes medidas:

- **Anonimização:** dados de alunos e informações sensíveis são anonimizados antes de serem enviados ao modelo de IA, em conformidade com a LGPD (Brasil, 2018).
- **Controle de acesso:** implementação de controle baseado em funções (*RBAC*), restringindo o acesso aos *dashboards* e *insights* conforme o perfil do gestor.
- **Validação de dados:** mecanismos de validação de entrada e saída para prevenir ataques de injeção de *prompt* e garantir a integridade das informações geradas.

A auditoria e o monitoramento contínuo para detecção de ameaças em tempo real foram definidos como requisitos arquiteturais do sistema, mas ainda não foram implementados no protótipo atual, permanecendo como direção para trabalhos futuros.

Os procedimentos de tratamento e responsabilização dos dados também consideraram as orientações da Autoridade Nacional de Proteção de Dados (ANPD, 2021).

3.4 Métricas de Avaliação

A eficácia do sistema foi avaliada por meio de três métricas objetivas:

- **Compressão informacional:** razão entre o volume de dados brutos processados e a quantidade de texto gerado (por exemplo, centenas de registros sintetizados em poucos parágrafos).
- **Cobertura dos *KPIs*:** percentual de indicadores críticos, definidos pelos pesquisadores com base no conjunto de dados experimental, corretamente abordados pelos *insights* da IA.
- **Número de *insights* relevantes:** quantidade de observações consideradas corretas, pertinentes e acionáveis, após comparação com os dados de origem.

Considerou-se que um *KPI* foi corretamente coberto quando o texto gerado identificou sua condição principal, apresentou valores compatíveis com os dados de origem e não introduziu informações inexistentes. As classificações foram revisadas pelos pesquisadores antes do cálculo da cobertura. Além da compatibilidade numérica, verificou-se se cada afirmação interpretativa poderia ser sustentada pelas variáveis disponíveis no conjunto de dados. Foram classificados como inadequados os textos que introduziram explicações causais, perfis de estudantes ou relações não representadas nos dados de entrada.

Complementando as métricas objetivas, os pesquisadores realizaram uma inspeção técnica qualitativa da interface. Essa análise avaliou a organização narrativa dos *insights*, a clareza da interface híbrida, a coerência entre os textos gerados e os dados de origem, e a facilidade de interpretação dos indicadores pelo gestor.

4. RESULTADOS E DISCUSSÃO

Os testes foram realizados com um conjunto de dados simulados, porém representativos, de *KPIs* de uma instituição de ensino superior. Os resultados indicam a viabilidade inicial da abordagem nas métricas efetivamente analisadas.

4.1 Eficiência na Geração de *Insights*

Em termos de compressão informacional, a IA condensou mais de mil registros em um resumo de aproximadamente 150 palavras. Essa medida representa a redução do volume textual apresentado, mas não avalia isoladamente a completude ou a facilidade de interpretação da síntese. Foram definidos cinco *KPIs* críticos para o conjunto experimental: taxa de evasão por turno, concentração de evasão por período, retenção por período, volume de matrículas e desempenho ENADE por turno. Nas sete execuções independentes realizadas, foram geradas 21 ocorrências dos mesmos três *insights* principais, todos classificados como corretos, pertinentes e acionáveis, resultando em uma cobertura estável de 80% (o sistema cobriu corretamente quatro dos cinco *KPIs* críticos, não identificando adequadamente o indicador de volume de matrículas). Como os *KPIs* partem de um conjunto de dados fixo, as execuções do Gemini avaliaram a estabilidade da síntese, e não uma variação dos indicadores. Os três *insights* únicos (Tabela 1) representam os quatro fenômenos críticos identificados, sendo evasão noturna acima do matutino, gargalo de retenção no 4º-6º período, desempenho ENADE mais baixo no noturno e concentração de saídas nos dois primeiros períodos, e foram classificados, após revisão dos pesquisadores, como corretos, pertinentes e acionáveis, evidenciando associações que demandariam análise manual demorada, como a ocorrência conjunta entre turno noturno, maior evasão (22,3% contra 14,5% no matutino) e conceito ENADE próximo do limite mínimo aceitável.

4.2 Potencial de Apoio à Interpretação e à Tomada de Decisão

A integração de *insights* diretamente nos *dashboards* apresentou potencial para facilitar a interpretação dos indicadores pelo gestor, ao disponibilizar informações previamente sintetizadas e contextualizadas, com potencial para acelerar a compreensão do cenário institucional. Na inspeção qualitativa realizada pelos dois pesquisadores, a interface híbrida (gráficos e explicações em linguagem natural) apresentou organização que sugere potencial para reduzir a carga cognitiva de leitura em comparação à versão tradicional, ainda que sem validação formal com usuários. A interface organizou os *insights* em uma sequência narrativa que priorizou situações críticas, contextualizou tendências e relacionou as explicações textuais aos respectivos indicadores gráficos, mostrando-se coerente com os princípios de *storytelling* visual adotados no projeto. A Tabela 1 exemplifica as saídas geradas e seu respectivo potencial de apoio na decisão institucional. As ações apresentadas constituem possibilidades de investigação e não recomendações conclusivas, devendo ser avaliadas por gestores e especialistas responsáveis.

Tabela 1 *- Exemplos de insights gerados automaticamente pela IA a partir de KPIs institucionais.*

KPI Analisado	Insight Gerado pela IA	Status	Possível Encaminhamento para Análise
Evasão	Alerta: A taxa de evasão no turno noturno foi de 22,3%, superior aos 14,5% observados no turno matutino, com maior concentração de saídas nos dois primeiros períodos.	Crítico	Investigar, junto aos estudantes do período noturno, fatores associados à evasão e avaliar a viabilidade de componentes híbridos, apoio financeiro ou outras medidas de permanência.
Retenção	Gargalo de retenção no miolo do curso (4º-6º período): 120 alunos retidos, coincidindo com disciplinas quantitativas (Estatística, Contabilidade de Custos, Matemática Financeira).	Atenção	Verificar se as disciplinas quantitativas estão associadas à retenção observada e avaliar ações de monitoria, nivelamento ou revisão pedagógica.
Desempenho Acadêmico	Conceito médio de concluintes de 3,1; o turno noturno opera no limite do conceito 2 (3,0), enquanto o matutino sustenta o índice (3,4).	Positivo/ Atenção	Investigar a relação entre o turno noturno e o desempenho no ENADE e avaliar a viabilidade de simulados direcionados a essa turma.

Fonte: Elaborado pelos autores (2026).

4.3 Cibersegurança e Confiabilidade

A arquitetura incorporou mecanismos de anonimização, controle de acesso e validação de entradas e saídas. Como os testes utilizaram dados simulados e não incluíram uma avaliação formal de segurança, os resultados constituem apenas um indício inicial de adequação técnica, a ser validado com testes específicos.

4.4 Limitações e Discussão Crítica

Os resultados obtidos com dados simulados são promissores, mas o sistema ainda depende de validação humana antes que seus alertas orientem decisões institucionais de forma autônoma, especialmente em situações críticas envolvendo evasão ou desempenho acadêmico. A confiabilidade dos *insights* gerados pela IA está diretamente associada à qualidade dos dados de entrada e à formulação dos *prompts* utilizados, o que aponta para a necessidade de testes com dados reais e de mecanismos de revisão por gestores antes da adoção em larga escala.

5. CONCLUSÕES E TRABALHOS FUTUROS

A implementação experimental de IA para a geração automática de *insights* em *dashboards* universitários demonstrou viabilidade inicial para sintetizar dados, identificar tendências e apresentar alertas de apoio à análise institucional. Os resultados indicam potencial de aplicação, mas ainda dependem de validação com dados reais, gestores e testes específicos de segurança antes de uma implantação operacional. Do ponto de vista institucional, o projeto também contribuiu como plataforma de pesquisa e inovação tecnológica.

Como trabalhos futuros, propõe-se personalizar os alertas conforme o perfil de responsabilidade do gestor, implementar canais de *feedback* para refinar continuamente o modelo de IA e explorar abordagens multimodais para incorporar dados não textuais à interface. Por fim, ressalta-se que os resultados se restringem ao cenário experimental com dados simulados, sendo necessária validação adicional antes de sua generalização para outros contextos.

REFERÊNCIAS

ANDERSON, R. **Security engineering**: a guide to building dependable distributed systems. 3. ed. Hoboken: Wiley, 2020. Disponível em: https://www.cl.cam.ac.uk/archive/rja14/Papers/SEv3.pdf. Acesso em: 20 jun. 2026.

AUTORIDADE NACIONAL DE PROTEÇÃO DE DADOS (ANPD). **Guia orientativo para definição dos agentes de tratamento de dados pessoais e do encarregado.** Brasília, DF: ANPD, 2021. Disponível em: https://www.gov.br/anpd/pt-br/. Acesso em: 21 jun. 2026.

BRASIL. **Lei nº 13.709, de 14 de agosto de 2018** (Lei Geral de Proteção de Dados Pessoais - LGPD). Brasília, DF: Presidência da República, 2018.

DAVENPORT, T. H.; HARRIS, J. G. **Competing on analytics**: the new science of winning. Boston: Harvard Business School Press, 2007.

GOOGLE. **Gemini API documentation**. [S. l.]: Google, 2024. Disponível em: https://ai.google.dev/. Acesso em: 19 jun. 2026.

ISLAM, Mohammed Saidul; LASKAR, Md Tahmid Rahman; PARVEZ, Md Rizwan; HOQUE, Enamul; JOTY, Shafiq. **DataNarrative:** Automated Data-Driven Storytelling with Visualizations and Texts. Miami, Florida, USA. Association for Computational Linguistics, 2024. p. 19253-19286. Disponível em: https://aclanthology.org/2024.emnlp-main.1073/. Acesso em: 21 jul. 2026.

MCSILL, J. **Storytelling e inteligência artificial:** como reinventar o marketing digital com verdade, emoção e propósito. São Paulo: DVS Editora, 2025.

SHNEIDERMAN, B. **Information visualization**: designing for interaction. 2. ed. San Francisco: Morgan Kaufmann, 2004.